TP INTEGRADOR · ANÁLISIS DE DATOS · CEIA FIUBA · 2026

¿Cuánto dura un viaje en Ecobici?

De 3,56 millones de recorridos de 2024 a un dataset listo para entrenar un modelo de regresión que prediga la duración del viaje.

Regresión | Target: duración del viaje (min) | Se conoce: estación de origen, de destino y el momento del viaje

Juan Palomeque · Juan Pablo Alegre · Tomás Moretti

01 El dataset

3,56 M viajes registrados en 2024

17 variables originales

395 estaciones de origen

262.673 usuarios distintos

Fuente: Buenos Aires Data — Bicicletas públicas, recorridos realizados 2024. Cada fila es un viaje.

02 Lo que muestran los datos

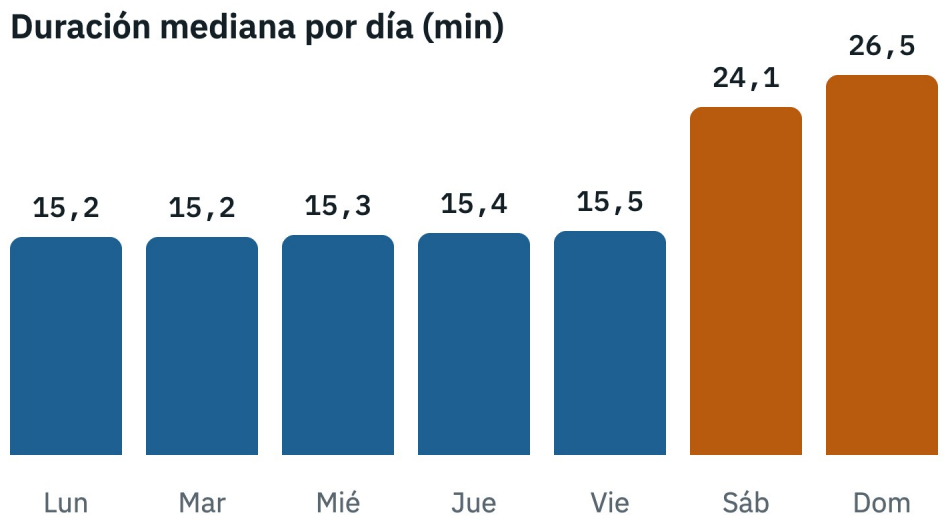
Una duración muy asimétrica

14,7 min · mediana

21,2 min · media

Asimetría de 156 y viajes de hasta 30 días: unos pocos extremos arrastran la media. Por eso usamos mediana e IQR.

Duración mediana por día (min)



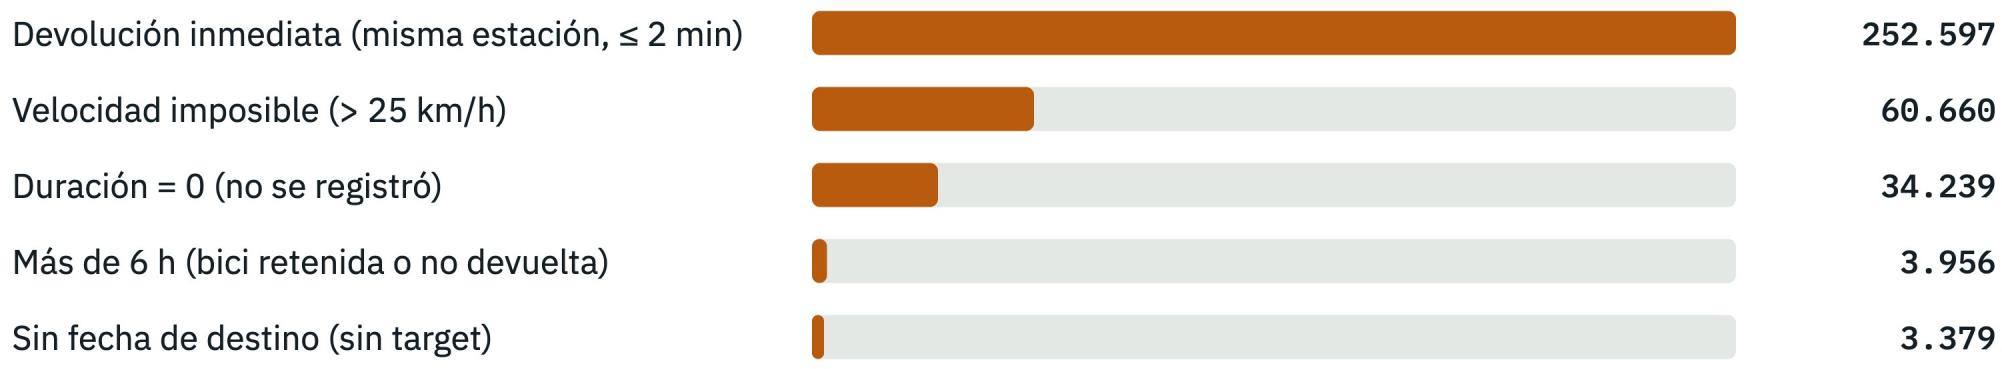
87%
de los viajes son en días hábiles, con picos a las 8 h y a las 17–18 h: la bici se usa como transporte.

+60–70%
más largos el fin de semana, con casi la misma distancia (1,7 vs 1,9 km): no se va más lejos, se pasea.

0,59
Spearman entre distancia y duración: la variable con más relación con la target.

03 Limpieza: el 10% no eran viajes

3.559.283 → **3.204.452** viajes (se conserva el 90%)



Reglas fijas fila por fila, por eso se aplican antes del split sin generar leakage. Un viaje de más de 6 h no es un error de registro, pero tampoco es un viaje en bici: queda fuera del alcance del problema.

04 Faltantes y valores extremos

Faltantes

`fecha_destino · 3.379 (0,09%)`
MAR: todos desde el 7/11/2024 y con duración 0. No tienen target → se eliminan.

`genero · 11.946 (0,34%)`
535 usuarios que nunca informaron su género → nueva categoría NO_INFORMADO.

Valores extremos de la duración

`IQR → > 49 min · 197.787 viajes`
Casi todos son paseos reales: la cola es larga, no los datos sucios. 3σ da un límite de 500 min, inflado por los extremos.

`Capping en p99 = 98,6 min`
Calculado y aplicado solo en train (25.632 viajes). y_test queda con la duración real.

05 Del dato crudo al dataset de entrenamiento

1 — Split 80/20

2.563.561 viajes de train y 640.891 de test.

2 — Faltantes

Género sin dato → categoría NO_INFORMADO.

3 — Outliers

Capping de la target en el p99, solo en train.

4 — Nuevas features

Distancia (haversine), misma estación, hora, día, mes, finde y hora pico.

5 — Codificación

Binaria, one-hot, cíclica (seno y coseno), frequency y target encoding.

6 — Escalado

Z-score sobre las 8 numéricas continuas.

7 — Selección

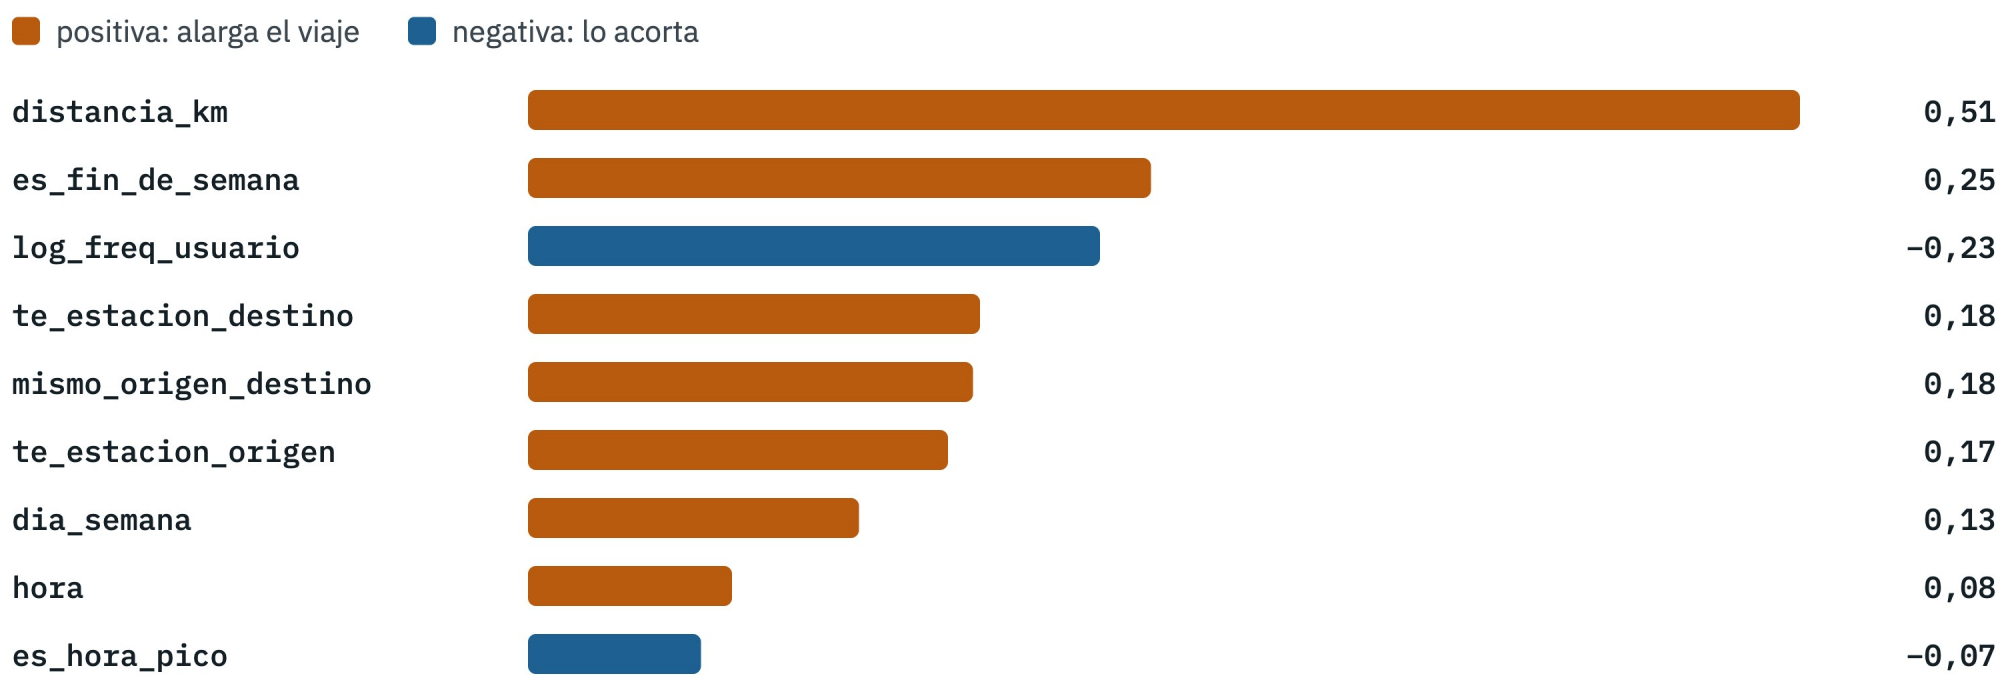
Spearman, V de Cramér, punto biserial, eta², test F e información mutua.

8 — PCA

8 numéricas → 5 componentes con el 88% de la varianza.

REGLA Todo lo que se calcula (medias, percentiles, encodings, ejes de PCA) se ajusta en **train** y se aplica en **test**.

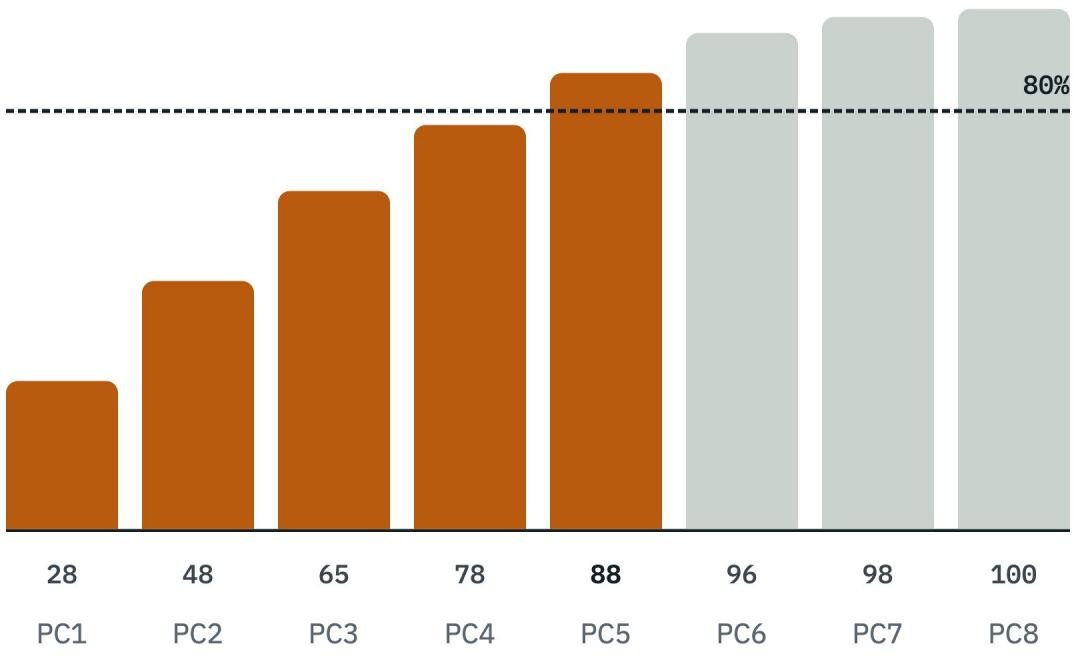
06 ¿Qué features se relacionan con la duración?



Spearman (numéricas) y punto biserial (binarias) con la duración, sobre 200 mil viajes de train. Las coordenadas dan relación lineal casi nula, pero información mutua apreciable: la ubicación importa de forma no lineal.

07 PCA: 8 variables en 5 componentes

Varianza acumulada (%)



Qué resume cada componente

PC1 y PC3
Las 4 coordenadas: dónde ocurre el viaje en la ciudad.

PC2
Target encoding de las estaciones.

PC4
Casi pura distancia.

PC5
Casi pura frecuencia del usuario.

PCA busca varianza, no relación con la duración: es no supervisado.

08 Resultado y conclusiones

X_train
2.563.561 × 22
filas × features

X_test
640.891 × 22
filas × features

Versión con PCA
19 columnas
para comparar al modelar

La distancia manda

Es la feature más predictiva, seguida por el fin de semana, la frecuencia del usuario y las estaciones.

Relación ruidosa

El mismo trayecto puede ser un traslado o un paseo: esperamos que modelos no lineales (árboles, boosting) funcionen mejor.

Leakage evitado

fecha_destino define la duración (destino – origen), así que quedó afuera de las features.

PCA, opcional

Con pocas features y millones de filas no es imprescindible: preferimos la versión sin PCA por interpretabilidad.